

Lab02

Matheus Soares - RA:277210

Pacotes utilizados

```
library(dplyr)
```

```
Attaching package: 'dplyr'
```

```
The following objects are masked from 'package:stats':
```

```
filter, lag
```

```
The following objects are masked from 'package:base':
```

```
intersect, setdiff, setequal, union
```

```
library(readr)
library(ggcal)
library(ggplot2)
```

Questão 1 - Estatísticas suficientes

O que queremos no final é um **percentual** (proporção de voos atrasados). Uma proporção só precisa de duas coisas para ser calculada, não importa o tamanho do lote de dados:

- `n_atrasados`: quantos voos tiveram `ARRIVAL_DELAY > 10`
- `n_total`: quantos voos existem no grupo (dia/mês/cia)

Com esses dois números dá pra calcular `Perc = n_atrasados / n_total`.

Questão 2 - Função `getStats`

```
getStats <- function(input, pos){
  input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(ARRIVAL_DELAY), !is.na(DAY), !is.na(MONTH), !is.na(AIRLINE))
```

```
%>%
group_by(DAY, MONTH, AIRLINE) %>%
summarise(
  n_atrasados = sum(ARRIVAL_DELAY > 10),
  n_total     = n(),
  .groups = "drop"
)
}
```

Questão 3 - Leitura em chunks com read_csv_chunked

```
lista_resultados <- list()

minha_callback <- function(x, pos){
  lista_resultados[[length(lista_resultados) + 1]] <- getStats(x, pos)
}

read_csv_chunked(
  file      = "flights.csv",
  callback  = DataFrameCallback$new(minha_callback),
  chunk_size = 100000,
  col_types = cols_only(
    MONTH      = col_integer(),
    DAY        = col_integer(),
    AIRLINE     = col_character(),
    ARRIVAL_DELAY = col_double()
  )
)
```

```
# A tibble: 1,478 × 5
  DAY MONTH AIRLINE n_atrasados n_total
  <int> <int> <chr>         <int>   <int>
1     1     1 AA             514    1379
2     1     1 DL             132    1558
3     1     1 UA             367    1269
4     1     1 US             201    1028
5     2     1 AA             649    1508
6     2     1 DL             406    2261
7     2     1 UA             493    1411
8     2     1 US             229    1174
9     3     1 AA             767    1425
10    3     1 DL             702    2021
# i 1,468 more rows
```

```
stats_parcial <- bind_rows(lista_resultados)
```

Questão 4 - Função computeStats

```
computeStats <- function(stats){  
  
  stats %>%  
    group_by(AIRLINE, MONTH, DAY) %>%  
    summarise(  
      n_atrasados = sum(n_atrasados),  
      n_total      = sum(n_total),  
      .groups = "drop"  
    ) %>%  
    mutate(  
      Data = as.Date(paste(2015, MONTH, DAY, sep = "-")),  
      Perc = n_atrasados / n_total  
    ) %>%  
    rename(Cia = AIRLINE) %>%  
    select(Cia, Data, Perc)  
  
}  
  
stats_final <- computeStats(stats_parcial)
```


Questão 5 - Mapas de calor tipo calendário (ggcal)

```
pal <- scale_fill_gradient(low = "blue", high = "red")  
  
baseCalendario <- function(stats, cia){  
  
  sub <- stats %>% filter(Cia == cia)  
  
  ggcal(sub$Data, sub$Perc)  
  
}  
  
cAA <- baseCalendario(stats_final, "AA")  
cDL <- baseCalendario(stats_final, "DL")  
cUA <- baseCalendario(stats_final, "UA")  
cUS <- baseCalendario(stats_final, "US")
```

American Airlines (AA)

```
cAA + pal + ggtitle("Percentual de atrasos - American Airlines (AA)")
```


Percentual de atrasos - American Airlines (AA)



Delta Air Lines (DL)

```
cDL + pal + ggtitle("Percentual de atrasos - Delta Air Lines (DL)")
```


Percentual de atrasos - Delta Air Lines (DL)



United Airlines (UA)

```
cUA + pal + ggtitle("Percentual de atrasos - United Airlines (UA)")
```


Percentual de atrasos - United Airlines (UA)



US Airways (US)

```
cUS + pal + ggtitle("Percentual de atrasos - US Airways (US)")
```

Percentual de atrasos - US Airways (US)



Hora:

```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-25 06:53:56 -03"
```